

# Théorie des langages : Généralités

## 1 Alphabets

Définition : (Alphabet/Vocabulaire)

On appelle alphabet ou vocabulaire tout ensemble fini.

Définition : (Lettres)

Les éléments d'un alphabet sont appelés des lettres

## 2 Mots

Définition : (Mot)

Soit  $A$  un alphabet,

Un mot sur  $A$  est une suite finie à valeurs dans  $A$ .

L'ensemble des mots de  $A$  est noté  $A^*$

Remarques :

- Soit  $\alpha$  un mot sur  $A$ ,  $\alpha : [1, n] \rightarrow A$
- $n$  s'appelle la longueur du mot, on note  $|\alpha| = n$
- Pour  $i \in [1, n]$ ,  $\alpha(i)$  ou  $\alpha_i$  désigne la  $i$ ème lettre de  $\alpha$
- Si  $n = 0$ ,  $\alpha$  est le mot vide, noté  $\varepsilon$  (ou  $\wedge$ )

Définition : (Egalité de 2 mots)

Deux mots  $\alpha$  et  $\beta$  sont égaux si et seulement si :

$$\begin{cases} |\alpha| = |\beta| = n \\ \forall i \in [1, n], \alpha_i = \beta_i \end{cases}$$

Notation :

Soit  $A$  un alphabet,  $a \in A$  et  $\alpha \in A^*$ , on note  $|\alpha|_a$  le nombre d'occurrences de la lettre  $a$  dans le mot  $\alpha$ .

Définition : (Concaténation de 2 mots)

Soit  $A$  un alphabet,

La concaténation est une opération définie sur  $A^*$  de la façon suivante :

$$\begin{aligned} . : A^* \times A^* &\rightarrow A^* \\ (\alpha, \beta) &\mapsto \alpha.\beta \end{aligned}$$

Où  $\alpha = \alpha_1\alpha_2\dots\alpha_p, \beta = \beta_1\beta_2\dots\beta_q$  et  $\alpha.\beta = \alpha_1\alpha_2\dots\alpha_p\beta_1\beta_2\dots\beta_q$

**Proposition :**

L'opération de concaténation possède les propriétés suivantes :

- $\forall \alpha, \beta \in A^*, |\alpha.\beta| = |\alpha| + |\beta|$
- $\forall \alpha, \beta, \gamma \in A^*, (\alpha.\beta).\gamma = \alpha.(\beta.\gamma)$  (Associativité)
- $\forall \alpha \in A^*, \alpha.\varepsilon = \varepsilon.\alpha = \alpha$  ( $\varepsilon$  est l'élément neutre de la concaténation)
- $\forall \alpha \in A^*, \alpha.\alpha = \alpha \Leftrightarrow \alpha = \varepsilon$  ( $\varepsilon$  est le seul mot idempotent)

Définition (Facteur, facteur propre)

Soient  $A$  un alphabet,  $\alpha, \beta \in A^*$ ,

On dit que  $\alpha$  est facteur de  $\beta$  si :

$$\exists \gamma, \delta \in A^*, \beta = \gamma\alpha\delta$$

Si de plus,  $\alpha \neq \beta$  et  $\alpha \neq \varepsilon$ , alors  $\alpha$  est dit facteur propre de  $\beta$

Définition : (Préfixe, préfixe propre)

Soient  $A$  un alphabet,  $\alpha, \beta \in A^*$ .

On dit que  $\alpha$  est préfixe de  $\beta$  et l'on note  $\alpha \sqsubseteq \beta$  si :

$$\exists \delta \in A^*, \beta = \alpha.\delta$$

Si  $\alpha \neq \beta$  et  $\alpha \neq \varepsilon$ , alors  $\alpha$  est dit préfixe propre de  $\beta$  et l'on note alors  $\alpha \sqsubset \beta$

Remarque : La relation  $\sqsubseteq$  est une relation d'ordre

Définition : (Suffixe, suffixe propre)

Soient  $A$  un alphabet,  $\alpha, \beta \in A^*$ .

On dit que  $\alpha$  est suffixe de  $\beta$  si :

$$\exists \gamma \in A^*, \beta = \gamma.\alpha$$

Si  $\alpha \neq \beta$  et  $\alpha \neq \varepsilon$ , alors  $\alpha$  est dit suffixe propre de  $\beta$

### 3 Langages

Définition : (Langage)

Soit  $A$  un alphabet,

On appelle langage sur  $A$  toute partie  $L$  de  $A^*$ . L'ensemble des langages sur  $A$  est donc  $\mathcal{P}(A) = \{L \mid L \subset A^*\}$  Un langage sur un alphabet est donc un ensemble de mots sur cet alphabet.

#### 3.1 Opérations ensemblistes sur les langages

Définition : (Union de 2 langages)

Soient  $L_1$  et  $L_2$  deux langages sur  $A$

On appelle union de  $L_1$  et  $L_2$  et l'on note  $L_1 \cup L_2$  (ou  $L_1 + L_2$ ) le langage défini par :

$$L_1 \cup L_2 = L_1 + L_2 = \{\alpha \in A^* \mid \alpha \in L_1 \text{ OU } \alpha \in L_2\}$$

Définition : (Intersection de 2 langages)

Soient  $L_1$  et  $L_2$  deux langages sur  $A$ .

On appelle intersection de  $L_1$  et  $L_2$  et l'on note  $L_1 \cap L_2$  le langage défini par :

$$L_1 \cap L_2 = \{\alpha \in A^* \mid \alpha \in L_1 \text{ ET } \alpha \in L_2\}$$

Définition : (Complémentaire d'un langage)

Soit  $L$  un langage sur  $A$ .

On appelle complémentaire de  $L$  et l'on note  $\bar{L}$  le langage défini par :

$$\bar{L} = A^* \setminus L = \{\alpha \in A^* \mid \alpha \notin L\}$$

Définition : (Différence symétrique)

Soient  $L_1$  et  $L_2$  deux langages sur  $A$ .

On appelle différence symétrique (ou réunion disjointe) entre  $L_1$  et  $L_2$  et l'on note  $L_1 \Delta L_2$  le langage défini par :

$$L_1 \Delta L_2 = \{\alpha \in A^* \mid \alpha \in L_1 \oplus \alpha \in L_2\} = L_1 \cup L_2 \setminus L_1 \cap L_2$$

On s'autorise également l'utilisation des autres opérations ensemblistes (produit cartésien, différence, ...) même si l'on n'en rappelle pas les définitions.

#### 3.2 Produit de langages

Définition : (Produit de 2 langages)

Soient  $L_1$  et  $L_2$  deux langages sur  $A$ .

On appelle produit (ou concaténation) de  $L_1$  et  $L_2$  et l'on note  $L_1.L_2$  le langage défini par :

$$L_1.L_2 = \{\gamma \in A^* \mid \exists (\alpha, \beta) \in L_1 \times L_2, \gamma = \alpha.\beta\}$$

Définition : Puissance nième

Soit  $L$  un langage sur  $A$ .

On appelle puissance nième de  $L$  et l'on note  $L^n$  le langage défini par :

$$\begin{cases} L^0 = \{\varepsilon\} \\ L^1 = L \\ L^n = L.L^{n-1} \quad \text{si } n > 1 \end{cases}$$

### 3.3 Itéré d'un langage

Définition : Itéré d'un langage

Soit  $L$  un langage sur  $A$ .

On appelle fermeture itérative (ou étoile ou fermeture de Kleene) de  $L$  et l'on note  $L^*$  le langage défini par :

$$L^* = \bigcup_{n \geq 0} L^n = \sum_{n \geq 0} L^n$$

Il s'agit du plus petit langage sur  $A$  contenant  $L$ , le mot vide et stable par concaténation.

Définition : (Itéré strict)

Soit  $L$  un langage sur  $A$ .

On appelle étoile stricte (ou itéré strict) de  $L$  et l'on note  $L^+$  le langage défini par :

$$L^+ = \bigcup_{n > 0} L^n = \sum_{n > 0} L^n$$

Il s'agit du plus petit langage sur  $A$  contenant  $L$ , et stable par concaténation.

*Remarques :*

- $L^* = L^+ \cup \{\varepsilon\}$
- $L^+ = L.L^*$
- $L^* = L^+ \Leftrightarrow \varepsilon \in L$

### 3.4 Langage miroir

Définition : (Langage miroir)

Soit  $L$  un langage sur  $A$ .

On appelle miroir (ou réfléchi) de  $L$  et l'on note  $\tilde{L}$  le langage défini par :

$$\tilde{L} = \{\phi(\alpha) \mid \alpha \in L\}$$

où  $\phi : A^* \rightarrow A^*$  est l'application définie par :

$$\begin{cases} \phi(\varepsilon) = \varepsilon \\ \forall \alpha \in A^*, a \in A, \phi(a.\alpha) = \phi(\alpha).a \end{cases}$$

*Remarque :*

$\phi$  est la fonction qui renverse un mot :

$$\phi(\alpha_1 \alpha_2 \dots \alpha_n) = \alpha_n \dots \alpha_2 \alpha_1$$

### 3.5 Quotients

Définition : (Quotient gauche)

Soient  $L_1$  et  $L_2$  deux langages sur  $A$ .

On appelle quotient gauche de  $L_2$  par  $L_1$  et l'on note  $L_1^{-1}.L_2$  le langage défini par :

$$L_1^{-1}.L_2 = \{\gamma \in A^*, \exists \alpha \in L_1, \alpha.\gamma \in L_2\}$$

Définition : (Quotient droit)

Soient  $L_1$  et  $L_2$  deux langages sur  $A$ .

On appelle quotient droit de  $L_1$  par  $L_2$  et l'on note  $L_1.L_2^{-1}$  le langage défini par :

$$L_1.L_2^{-1} = \{\gamma \in A^*, \exists \alpha \in L_2, \gamma.\alpha \in L_1\}$$

## 4 Propriétés des opérations

Propriétés de l'union et du produit

L'union est associative, commutative, d'élément neutre  $\emptyset$  et d'élément absorbant  $A^*$ . Autrement dit,  $\forall L, L_1, L_2, L_3 \in \mathcal{P}(A^*)$  :

- $(L_1 \cup L_2) \cup L_3 = L_1 \cup (L_2 \cup L_3)$

- $L_1 \cup L_2 = L_2 \cup L_1$
- $\emptyset \cup L = L \cup \emptyset = L$
- $L \cup A^* = A^* \cup L = A^*$

Le produit est associatif, d'élément neutre  $\{\varepsilon\}$ , d'élément absorbant  $\emptyset$  et distributif par rapport à l'union. Autrement dit,  $\forall L, L_1, L_2, L_3 \in \mathcal{P}(A^*)$  :

- $(L_1.L_2).L_3 = L_1.(L_2.L_3)$
- $\{\varepsilon\}.L = L.\{\varepsilon\} = L$
- $\emptyset.L = L.\emptyset = \emptyset$
- $L_1.(L_2 \cup L_3) = L_1.L_2 \cup L_1.L_3$

*Remarque :*

Le produit n'est pas commutatif en général (sauf si  $\text{card}(A) = 1$ )

#### **Propriétés de l'étoile et de l'étoile stricte**

L'opération de fermeture itérative (ainsi que l'étoile stricte) est idempotente, autrement dit  $\forall L \in \mathcal{P}(A^*)$  :

- $(L^*)^* = L^*$
- $(L^+)^+ = L^+$

De plus on a  $\forall L_1, L_2 \in \mathcal{P}(A), (L_1^* + L_2^*)^* = (L_1 + L_2)^* = (L_1^*.L_2^*)^*$

## 5 Langages réguliers et expressions régulières

#### Définition : Ensemble des langages réguliers

L'ensemble  $\mathcal{Rat}(A^*)$  des langages rationnels (ou réguliers) sur un alphabet  $A$  est défini inductivement par :

- La base  $B = \{\emptyset, \{\varepsilon\}\} \cup \{\{a\} \mid a \in A\}$
- L'ensemble des opérations  $\mathcal{O}_p = \{\text{union, produit, itéré}\}$

*Remarque :*

On définit parfois la base comme étant l'ensemble de tous les langages finis sur  $A$

#### Définition : Ensemble des expressions régulières

L'ensemble  $\mathcal{R}_A$  des expressions régulières (ou rationnelles) sur un alphabet  $A$  est défini inductivement de la façon suivante :

- La base  $B = \{\emptyset, \varepsilon\} \cup \{\{a\} \mid a \in A\}$
- L'ensemble des opérations  $\mathcal{O}_p : \{\forall e_1 \in \mathcal{R}_A, \forall e_2 \in \mathcal{R}_A, (e_1 + e_2) \in \mathcal{R}_A; (e_1 e_2) \in \mathcal{R}_A; (e_1)^* \in \mathcal{R}_A; (e_1)^+ \in \mathcal{R}_A\}$

*Remarque :*

Les expressions régulières forment un langage sur l'alphabet  $A \cup \{\emptyset, \varepsilon, +, *, *, (, )\}$

#### Définition :

On définit une application  $\mathcal{L} : \mathcal{R}_A \rightarrow \mathcal{Rat}(A^*)$  de la manière suivante (Avec  $a \in A$  et  $e_1, e_2, e \in \mathcal{R}_A$ ) :

- $\mathcal{L}(\emptyset) = \emptyset$
- $\mathcal{L}(\varepsilon) = \{\varepsilon\}$
- $\mathcal{L}(a) = \{a\}$
- $\mathcal{L}((e_1 + e_2)) = \mathcal{L}(e_1) \cup \mathcal{L}(e_2)$
- $\mathcal{L}((e_1 e_2)) = \mathcal{L}(e_1). \mathcal{L}(e_2)$
- $\mathcal{L}((e)^*) = \mathcal{L}(e)^*$
- $\mathcal{L}((e)^+) = \mathcal{L}(e)^+$

Soient  $\alpha$  un langage et  $e$  une expression régulière tels que  $\mathcal{L}(e) = \alpha$ , on dit que  $e$  dénote  $\alpha$

#### **Théorème :**

Un langage est régulier si et seulement si il est dénoté par une expression régulière.

## 6 Code

### 6.1 Définition et propriétés

#### Définition : Code

Soit  $C$  un langage.

On dit que  $C$  est un code s'il n'existe pas de mot de  $C^*$  ayant 2 factorisation différentes avec des mots de  $C$ .

#### **Proposition :**

Soit  $C$  un sous ensemble fini de  $A^+$ .

Si  $C$  est un code, alors tout sous ensemble de  $C$  est un code.

#### **Propositions / Définitions :**

Soit  $C$  un sous-ensemble fini de  $A^*$  :

- Si  $C$  est un code,  $\varepsilon \in C$
- Si  $C$  est un code,  $C$  et  $\bigcup_{n \geq 2} C^n$  sont 2 ensembles disjoints

- Si tous les mots de  $C$  sont de même longueur non nulle alors  $C$  est un code. On parle alors de code **uniforme**
- Si aucun mot de  $C$  n'est préfixe (resp. suffixe) d'un autre mot de  $C$ ,  $C$  est un code. Dans ce cas, le code  $C$  est qualifié de code **préfixe** (resp. **suffixe**)

## 6.2 Algorithme de Sardinas Patterson

### Algorithme

Soit  $C \in \mathcal{P}(A^*)$ .

On cherche à déterminer si  $C$  est un code. L'algorithme de Sardinas-Patterson consiste en la construction d'une suite d'ensembles :

- *Initialisation* :  $U_0 = C^{-1}.C \setminus \{\varepsilon\}$
- *Itération* :  $U_{n+1} = U_n^{-1}.C \cup C^{-1}.U_n$
- *Condition d'arrêt* :  $\begin{cases} \varepsilon \in U_n \Rightarrow C \text{ n'est pas un code} \\ \exists i \exists j, i > j \text{ et } U_i = U_j \Rightarrow C \text{ est un code} \end{cases}$